

ИНСТРУКЦИЯ ПО СОЗДАНИЮ

# Голосовой чеклист клиента

AI-помощник для менеджеров школы арабского языка:  
от пустой папки до боевого сервера на DigitalOcean + Coolify

Whisper · распознавание речи

MiniMax M3 · анализ ответов

DigitalOcean + Coolify · хостинг

01

# Что это и какую проблему решает

## ПРОБЛЕМА

Менеджер общается с клиентами в Telegram, WhatsApp и по телефону. После каждого разговора нужно заполнить карточку клиента в CRM — печатать долго, лень, детали забываются.

## РЕШЕНИЕ

После разговора менеджер наговаривает голосом ответы на 10 вопросов о клиенте. AI транскрибирует речь, раскладывает по категориям и отдаёт готовый чеклист для CRM.

**7 мин**

на одного клиента вместо 20 минут печатания

**10**

фиксированных вопросов — данные сопоставимы от клиента к клиенту

**1 ₽**

стоимость AI-обработки одного чеклиста

## 02

## Как этим пользуется менеджер

1

### Открывает сайт

Сразу после разговора с клиентом. Никакой регистрации — открыл ссылку и работаешь.

2

### Говорит ответы

10 вопросов в 3 раунда.  
Жмёт кнопку записи, говорит своими словами, жмёт стоп.

3

### Проверяет текст

Whisper показывает черновик транскрипции. Имена и термины можно поправить руками.

4

### Скачивает файл

Готовый чеклист .md по 6 категориям со статусами. Кидает в CRM или чат команды.

**Важно:** это конспект ПОСЛЕ разговора. Менеджер не записывает клиента и не читает вопросы вслух — он пересказывает итоги своими словами.

03

## Шаблон: 10 вопросов в 3 раунда

### Раунд 1 · Знакомство

4 вопроса

- Имя и где находится (страна, часовой пояс)
- Откуда узнал о школе — источник лида
- Зачем учит арабский — мотивация
- Какой диалект: MSA, египетский, левантийский...

### Раунд 2 · Опыт и формат

3 вопроса

- Текущий уровень владения арабским
- Опыт онлайн-курсов: что нравилось, что нет
- Готовность к Zoom или асинхронный формат

### Раунд 3 · Условия

3 вопроса

- Сколько часов в день и в неделю готов уделять
- Бюджет на обучение
- Пожелания: пол преподавателя, удобное время

**Почему вопросы фиксированные?** Для продаж важна повторяемость данных. AI не выдумывает вопросы — он только анализирует ответы и собирает итоговый чеклист.

## 04

# Архитектура: четыре звена



## Whisper работает локально

Распознавание речи на нашем сервере. Аудио не уходит третьим лицам — важно для данных клиентов.

## LLM — только анализ

MiniMax M3 вызывается 3 раза за сессию: 2 резюме раундов + 1 финальный чеклист. Отсюда цена  $\approx 1$  ₽.

## Один docker-compose

Frontend и backend упакованы в контейнеры. Один файл описывает всю систему — Coolify читает его напрямую.

## Frontend

Next.js 16, React 19, TypeScript, Tailwind 4 — страницы, запись звука, прогресс раундов

## Backend

Python 3.11, FastAPI, LangGraph — API, логика раундов, сборка чеклиста

## Распознавание речи

Whisper (модель small/medium) локально + ffmpeg для конвертации звука из браузера

## Языковая модель

MiniMax M3 через OpenRouter — резюме раундов и финальный чеклист в JSON

## Упаковка

Docker: два образа (frontend, backend) + docker-compose как общее описание

## Хостинг

DigitalOcean droplet + Coolify (панель, SSL, авто-деплой) · frontend на Vercel CDN

## 06

# Шаг 1. Собираем backend

Python-сервер, который принимает звук, превращает его в текст и собирает чеклист.

## FastAPI — шесть точек входа

Старт сессии, транскрипция, сабмит раунда, результаты, скачивание .md, health-проверка.

## Whisper + ffmpeg

Браузер пишет звук в формате webm. ffmpeg конвертирует его в wav 16 кГц — только такой формат Whisper умеет читать.

## LangGraph — логика раундов

После раунда: резюме ответов → если раунды остались, отдать следующие вопросы; если нет — собрать финальный чеклист.

## Вопросы — в коде, не в AI


10 вопросов лежат в файле questions\_template.py. Поменять формулировку = поправить одну строку.

**Секреты:** ключ OPENROUTER\_API\_KEY живёт только в .env-файле, который никогда не попадает в git.

## 07 Шаг 2. Собираем frontend

Три страницы на Next.js: главная, сессия с записью голоса, итоговый чеклист.

Сердце интерфейса — кнопка записи с пятью состояниями:



### Черновик можно править

Whisper иногда ошибается в именах и арабских терминах. Менеджер видит текст до отправки и правит руками — дешевле, чем разбирать кривой чеклист потом.

### Mock-режим для разработки

Переменная `NEXT_PUBLIC_USE MOCK=true` включает предзаписанные ответы — интерфейс можно смотреть и улучшать без бэкенда и микрофона.

08

## Шаг 3. Проверяем локально

Прежде чем платить за сервер — убеждаемся, что всё работает на своём компьютере.

1

### Smoke-тест языковой модели

Маленький скрипт шлёт один запрос в OpenRouter и проверяет, что MiniMax M3 отвечает корректным JSON. Стоимость теста — доли копейки.

2

### Интерфейс в mock-режиме

Запускаем frontend с предзаписанными данными. Кликаем весь путь: главная → 3 раунда → чеклист. Правим дизайн, пока не понравится.

3

### Полный прогон с микрофоном

Поднимаем backend (нужны Python, ffmpeg и ~3 ГБ под Whisper), выключаем mock — и проходим сессию реальным голосом.

## Шаг 4. Docker и GitHub

Упаковываем обе части в контейнеры и заливаем код в репозиторий — основа для деплоя.

### Два Dockerfile

- backend: Python + ffmpeg + Whisper; модель скачивается при сборке — быстрый старт
- frontend: standalone-сборка Next.js, образ ~150 МБ вместо гигабайта

### docker-compose.yml

- Один файл описывает оба контейнера, переменные окружения и порты
- Coolify читает его напрямую — отдельная настройка не нужна

### GitHub

- Код в приватный или публичный репозиторий — удобно через GitHub Desktop
- В .gitignore: ключи (.env), node\_modules, кеш моделей — секреты в git не попадают

**Зачем Docker?** Контейнер одинаково работает на ноутбуке, на бесплатном хостинге и на боевом сервере. Переезд = тот же образ на новом месте.

10

## Шаг 5. Арендуем сервер DigitalOcean

1

### Аккаунт DigitalOcean

cloud.digitalocean.com — почта + карта или PayPal.  
Подойдёт уже существующий аккаунт, новый не нужен.

2

### SSH-ключ

На своём компьютере: `ssh-keygen -t ed25519`. Публичная часть (.pub) вставляется в панель DO — вход без пароля.

3

### Создание droplet

Ubuntu 24.04 · Basic 4 ГБ RAM / 2 vCPU. Регион Frankfurt — центр между Россией и Египтом. Через минуту получаем IP.

4

### Домен и DNS

A-запись api.домен → IP droplet. Frontend остаётся на Vercel CDN — он уже задеплоен и бесплатен.

**\$24/мес** — стабильные ядра для Whisper, resize в пару кликов, сервер никогда не «засыпает».

# 11 Шаг 6. Ставим Coolify и деплоим

Coolify — бесплатная панель управления, которая превращает голый сервер в «свой Vercel».

## Установка одной командой

1

По SSH запускаем установочный скрипт с coolify.io. Через 5 минут панель доступна на `http://IP:8000`.

## Подключаем GitHub

2

Coolify ставит своё приложение на репозиторий. Новый проект → Docker Compose → выбираем репо и ветку main.

## Переменные окружения

3

OPENROUTER\_API\_KEY (секрет), домены фронта и бэка, язык Whisper. Всё через веб-форму.

## Домены и SSL

4

Прописываем app-домен и api-домен. Сертификаты Let's Encrypt выпускаются и продлеваются сами.

## Deploy

5

Кнопка Deploy: Coolify собирает оба образа и запускает. Первая сборка ~15 минут, дальше быстрее.

## Авто-деплой

6

Включаем Deploy on Push: каждый git push в main автоматически обновляет прод.

## 12 Проверяем и считаем деньги

### Чек-лист после деплоя

- ✓ api.домен/health отвечает: whisper загружен
- ✓ api.домен/docs — открывается документация API
- ✓ Frontend на Vercel открывается, стили школы на месте
- ✓ Запись голоса → транскрипция приходит
- ✓ Полная сессия: 3 раунда → чеклист → скачали .md
- ✓ Сертификат: замочек в браузере, https без ошибок

### Стоимость в месяц

Droplet DigitalOcean 4 ГБ

\$24 ≈ 2200 ₽

Домен .ru

≈ 17 ₽/мес

Coolify + Vercel

0 ₽

AI-обработка (30 клиентов)

≈ 30 ₽

**Итого: ≈ 2250 ₽/мес**

за инструмент для всего отдела продаж

# Готово. Что можно улучшить дальше

## Whisper-medium

Точнее распознаёт имена и арабские термины. Цена — чуть больше диска и пара секунд к ответу.

## Redis для сессий

Сейчас незаконченные сессии живут в памяти и теряются при перезапуске. Redis ставится в Coolify в один клик.

## Вход по паролю

Сейчас доступ по секретной ссылке. Authelia добавит логин и двухфакторку для менеджеров.

## Архив чеклистов

Сохранять готовые .md в хранилище — история работы с каждым клиентом в одном месте.

Менеджер говорит — **AI пишет** — школа растёт.